

CNN ile Akciğer Röntgeninden Zatürre Tespiti

Proje Raporu

Özet

Bu projede, göğüs röntgeni görüntülerinden **NORMAL** (zatürre bulgusu yok) ve **PNEUMONIA** (zatürre var) sınıflarını ayırt eden bir **derin öğrenme (CNN / transfer learning)** sistemi geliştirilmiştir. Chest X-Ray Images (Pneumonia) veri seti kullanılmış; veri doğrulama, keşifsel analiz, baseline CNN ve ResNet18 tabanlı transfer learning eğitimi, test değerlendirmesi, Grad-CAM açıklanabilirlik analizi ile FastAPI ve Streamlit demo katmanı uçtan uca uygulanmıştır. Test setinde model **%85,7 doğruluk**, **%99,5 recall** ve **0,96 ROC-AUC** değerlerine ulaşmıştır. Çalışma yalnızca **eğitim ve akademik** amaçlıdır; klinik teşhis aracı olarak kullanılmamalıdır.

1. Problem Tanımı

1.1 Problem

Girdi: Tek kanallı veya RGB'ye dönüştürülmüş bir göğüs röntgeni görüntüsü (JPEG/PNG).

Çıktı: Görüntünün **NORMAL** mi yoksa **PNEUMONIA** mı olduğuna dair ikili sınıflandırma; her sınıf için olasılık ve güven skoru.

Bu problem, bilgisayarlı görü (computer vision) alanında **görüntü sınıflandırma** (image classification) olarak modellenmiştir.

1.2 Problemin Önemi

Zatürre (pnömoni), akciğer dokusunu enfekte eden ve tedavi gecikirse ciddi komplikasyonlara yol açabilen yaygın bir hastalıktır. Göğüs röntgeni (chest X-ray), klinik pratikte sık kullanılan bir görüntüleme yöntemidir. Radyologların iş yükünü azaltmak ve erken uyarı sağlamak amacıyla, röntgen görüntülerinin otomatik analizi yıllardır araştırma konusudur.

Derin öğrenme modelleri bu tür görüntülerde belirli örüntüleri öğrenebilir; ancak **gerçek sağlık hizmetinde** kullanım için geniş klinik doğrulama, regülasyon, hasta güvenliği ve uzman denetimi şarttır. Bu proje, bu gerçek problemi **akademik ve eğitim** çerçevesinde ele alır; üretilen tahminler tıbbi karar yerine geçmez.

2. Kullanılan Yapay Zekâ Yöntemi ve Gerekçe

2.1 Yöntem Seçimi

Projede **derin öğrenme** tabanlı **evrimsel sinir ağları (CNN)** kullanılmıştır. İki aşamalı bir modelleme stratejisi izlenmiştir:

Aşama	Model	Amaç
Baseline	SimpleCNN (özel mimari)	Veri seti ve pipeline'ın çalıştığını doğrulamak; referans performans
Final	ResNet18 + transfer learning	ImageNet ön eğitilmiş özellik çıkarıcı ile daha güçlü temsil öğrenmek

Gerekçeler:

- Görüntü verisi:** Problem piksel tabanlıdır; CNN'ler uzamsal öznitelikleri hiyerarşik olarak öğrenmek için uygundur.
- Sınırlı veri:** Tamamen sıfırdan çok derin ağ eğitmek risklidir; **transfer learning** (ön eğitilmiş ResNet18) daha az veriyle daha iyi genelleme sağlar.
- ResNet mimarisi:** Artık bağlantılar (residual connections) gradyan kaybını azaltır; tıbbi görüntü sınıflandırma literatüründe yaygın kullanılır (ör. CheXNet çalışmaları).
- İkili sınıflandırma:** Çıktı katmanı 2 sınıflı softmax ile modellenmiş; kayıp fonksiyonu olarak **ağırlıklı çapraz entropi (weighted cross-entropy)** kullanılarak sınıf dengesizliği telafi edilmiştir.
- Açıklanabilirlik:** Grad-CAM ile modelin hangi bölgelere odaklandığı görselleştirilmiş; sonuçların yorumlanabilirliği artırılmıştır.

Alternatif olarak config dosyasında EfficientNet-B0 ve MobileNetV3-Small desteklenmektedir; final deneyler **ResNet18** ile yürütülmüştür.

2.2 Eğitim Stratejisi

Transfer learning **iki fazlı** uygulanmıştır:

1. **Sınıflandırıcı eğitimi (8 epoch):** ImageNet ağırlıklı backbone dondurulur; yalnızca son tam bağlı katman eğitilir.
2. **Fine-tuning (12 epoch):** ResNet'in son evrişim bloğu (layer4) ve sınıflandırıcı katmanı düşük öğrenme oranıyla birlikte güncellenir.

Optimizasyon: AdamW, ReduceLROnPlateau öğrenme oranı zamanlayıcısı, early stopping (patience=5).
En iyi model validation kaybına göre seçilmiştir.

3. Veri Seti

3.1 Kaynak

Chest X-Ray Images (Pneumonia) — Kaggle / Mendeley kaynaklı, çocuk hastaların ön-arka göğüs röntgenlerini içeren açık veri seti.

- Kaynak: <https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia>
- Ham veri projede data/raw/chest_xray/ altına **manuel** yerleştirilmiştir (otomatik indirme yoktur).

3.2 Yapı ve İstatistikler

Ham klasör yapısı:

```
chest_xray/  
├── train/   (NORMAL, PNEUMONIA)  
├── val/     (NORMAL, PNEUMONIA)  
└── test/    (NORMAL, PNEUMONIA)
```

Split	NORMAL	PNEUMONIA	Toplam
Train	1.341	3.875	5.216
Val (ham)	8	8	16
Test	234	390	624
Toplam	1.583	4.273	5.856

- Bozuk görüntü: **0**
- PNEUMONIA sınıfı veri setinin yaklaşık **%73'**ünü oluşturur → belirgin **sınıf dengesizliği**.

3.3 Validation Bölünmesi (Önemli Tasarım Kararı)

Ham val split'i yalnızca **16 görüntü** içerdiğinden model seçimi için yetersizdir. Bu nedenle:

- Ham **train** klasörü, sınıf oranları korunarak **%85 eğitim / %15 doğrulama** şeklinde stratified olarak yeniden bölünmüştür (seed=42).
- Ham **test** split'i değiştirilmeden kullanılmıştır.

Eğitimde kullanılan manifest dağılımı:

Manifest	NORMAL	PNEUMONIA	Toplam
----------	--------	-----------	--------

Eğitim	1.140	3.294	4.434
Doğrulama	201	581	782
Test	234	390	624

3.4 Ön İşleme ve Veri Artırma

- Görüntü boyutu: **256×256** piksel
- Normalizasyon: ImageNet ortalama ve standart sapması
- Mean: [0.485, 0.456, 0.406] — Std: [0.229, 0.224, 0.225]
- Eğitim:** yatay çevirme (%50), $\pm 7^\circ$ rotasyon (kontrollü)
- Doğrulama / test / tahmin:** yalnızca resize + normalizasyon (deterministik)

EDA bulguları: görüntü boyutları değişkendir (ortalama $\sim 1328 \times 971$ piksel); aspect ratio dağılımı geniştir; agresif augmentasyondan kaçınılmıştır.

4. Geliştirilen Çözüm (Uygulama)

4.1 Yazılım Mimarisi

Proje modüler Python paketi olarak yapılandırılmıştır:

Modül	Görev
src/data/	Veri doğrulama, manifest üretimi, PyTorch Dataset ve DataLoader
src/eda/	Keşifsel veri analizi ve özet raporlar
src/training/	Model tanımları ve eğitim döngüsü
src/evaluation/	Test metrikleri ve grafikler
src/inference/	Tek görüntü tahmini
src/explainability/	Grad-CAM
app/api/	FastAPI tahmin servisi
app/ui/	Streamlit demo arayüzü

Merkezi yapılandırma: configs/config.yaml. Kalite kontrol: **pytest** (34 test), **ruff** lint.

4.2 Deney Düzenegi

Parametre	Değer
Final model	ResNet18 (ImageNet ön eğitilmiş)
Görüntü boyutu	256
Batch size	24
Öğrenme oranı (sınıflandırıcı)	0,0003
Fine-tuning öğrenme oranı	0,00001
Toplam epoch	20 (8 + 12)
Seed	42
Cihaz	CUDA (GPU)

Ağırlıklı kayıp	Etkin
-----------------	-------

4.3 Baseline Karşılaştırma

Model	En iyi epoch	Val. accuracy	Val. F1
SimpleCNN (baseline)	8	0,9066	0,9362
ResNet18 (transfer learning)	18	0,9795	0,9862

Transfer learning, doğrulama setinde baseline'a göre belirgin üstünlük sağlamıştır.

5. Deneyler ve Sonuçlar

5.1 Test Seti Metrikleri (Final Model: ResNet18)

Test seti **624** görüntü üzerinde, hiç eğitimde kullanılmamış ham test split'inde ölçülmüştür.

Metrik	Değer
Accuracy (doğruluk)	0,8574 (%85,7)
Precision (kesinlik)	0,8168
Recall (duyarlılık)	0,9949
F1-score	0,8971
ROC-AUC	0,9599

Sınıf bazlı (özet):

Sınıf	Precision	Recall	F1
PNEUMONIA	0,8168	0,9949	0,8971
NORMAL	0,9866	0,6282	0,7676

5.2 Confusion Matrix

Gerçek \ Tahmin	NORMAL	PNEUMONIA
NORMAL	147 (TN)	87 (FP)
PNEUMONIA	2 (FN)	388 (TP)

- **True Positive (TP):** 388 — zatürre doğru tespit
- **True Negative (TN):** 147 — normal doğru tespit
- **False Positive (FP):** 87 — sağlıklı hasta yanlışlıkla zatürre
- **False Negative (FN):** 2 — zatürre yanlışlıkla normal (kaçırma)

5.3 Sonuçların Yorumu

Güçlü yönler:

- **Çok yüksek recall (%99,5):** Gerçek zatürre vakalarının neredeyse tamamı yakalanmıştır; yalnızca 2 görüntü kaçırılmıştır (FN=2). Akademik ve “erken uyarı” senaryolarında bu metrik öne çıkar.
- **Yüksek ROC-AUC (0,96):** Model, iki sınıfı olasılık eşiğine göre genel olarak iyi ayırt edebilmektedir.
- Transfer learning, baseline’a göre belirgin iyileşme sağlamıştır.

Zayıf yönler:

- **87 false positive:** Normal görüntülerin önemli bir kısmı yanlışlıkla PNEUMONIA sayılmıştır → **precision düşük** (%81,7). Klinikte gereksiz alarm ve ek tetkik riski oluşturur.
- **NORMAL sınıfında düşük recall (%62,8):** Sağlıklı hastaların yaklaşık üçte biri doğru NORMAL olarak sınıflandırılmamıştır.
- **Accuracy %85,7:** Dengesiz veri setinde tek başına yanıltıcı olabilir; precision-recall dengesi dikkatle incelenmelidir.

Tıbbi bağlam notu (akademik): Yüksek recall, zatürreyi kaçırmama açısından tercih edilebilir bir eğilim gösterir; ancak yüksek FP oranı, gerçek klinik kullanım için karar eşiği ayarı, uzman doğrulaması ve çok merkezli test gerektirir. **Bu sistem teşhis aracı değildir.**

5.4 Grad-CAM Açıklanabilirlik

Grad-CAM ile doğru ve hatalı tahmin örneklerinde modelin son evrişim katmanındaki aktivasyonları ısı haritası olarak görselleştirilmiştir. Amaç, modelin akciğer bölgesine mi yoksa kenar/işaret gibi ilgisiz alanlara mı odaklandığını incelemektir. Grad-CAM **yaklaşık** bir açıklamadır; patoloji lokalizasyonu veya nedensel kanıt sağlamaz.

5.5 Demo ve Servis Katmanı

- **FastAPI:** /health, /model-info, /predict — röntgen yükleme ile JSON tahmin
- **Streamlit:** Görüntü yükleme, önizleme, API üzerinden sonuç gösterimi
- Tüm çıktılarda: *“Bu çıktı tıbbi teşhis amacıyla kullanılmamalıdır.”*

6. Kısa Değerlendirme

6.1 Proje Kapsamı

Özellik	Karşılama
Gerçek hayat problemi	Göğüs röntgeninden zatürre sınıflandırması
Problem tanımı ve önemi	Bölüm 1
Uygun YZ yöntemi ve gerekçe	CNN + transfer learning (Bölüm 2)
Veri kullanımı	Açık veri seti, EDA, stratified split (Bölüm 3)
Kodlama / uygulama	Çalışır PyTorch pipeline, API, UI (Bölüm 4)
Sonuç analizi	Metrikler, confusion matrix, Grad-CAM (Bölüm 5)
Kaynak kod	src/, app/, scripts/, tests/, README
Rapor	Bu belge (~4–5 sayfa, Word/PDF’e aktarılabilir)

6.2 Sınırlılıklar

3. Tek veri seti, tek popülasyon (çoğunlukla pediatrik); dış doğrulama yok.
4. İkili sınıf; diğer akciğer patolojileri ayırt edilmez.
5. Yüksek FP oranı; eşik optimizasyonu yapılmamıştır.
6. Klinik onay, regülasyon ve etik onay kapsam dışıdır.
7. Grad-CAM görsel yorumu uzman radyolog yerine geçmez.

6.3 Sonuç

Proje, derin öğrenme ile anlamlı ve veri destekli bir sağlık görüntüleme problemini uçtan uca ele almıştır. ResNet18 transfer learning modeli test setinde güçlü ayırt etme (ROC-AUC) ve çok yüksek zatürre recall değerleri üretmiş; ancak false positive oranı yüksek kalmıştır. Kod modüler, test edilmiş ve demo ile sunulabilir durumdadır. Çalışma, uygulanabilir, ölçülebilir ve raporlanabilir bir proje örneği sunmaktadır.

Kaynakça

8. Kaggle — Chest X-Ray Images (Pneumonia).
<https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia>
9. Mendeley Data — Chest X-Ray Images (Pneumonia).
<https://data.mendeley.com/datasets/rscbjbr9sj/2>
10. Rajpurkar, P., et al. (2017). CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning. arXiv:1711.05225
11. He, K., et al. (2016). Deep Residual Learning for Image Recognition. arXiv:1512.03385
12. Selvaraju, R. R., et al. (2017). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. arXiv:1610.02391

Ek: Çalıştırma Özeti

```
# Kurulum
python -m pip install -e "[dev]"

# Veri hazırlığı (veri manuel yerleştirildikten sonra)
python -m src.data.validate_dataset --config configs/config.yaml
python -m src.data.standardize_dataset --config configs/config.yaml

# Eğitim ve değerlendirme
python -m src.training.train_baseline --config configs/config.yaml
python -m src.training.train --config configs/config.yaml
python -m src.evaluation.evaluate --config configs/config.yaml

# Demo
python -m uvicorn app.api.main:app --host 0.0.0.0 --port 8000
python -m streamlit run app/ui/streamlit_app.py
```

Proje kök dizini: pneumonia-xray-cnn — ayrıntılı kullanım için README.md dosyasına bakınız.